

1. sklop: Binomski model

Nina Ruzic Gorenjec

1 Primer

Izberite pravilni odgovor na spodnje vprasanje.

Vprasanje: Qskd senciljm dowdlq a?

- (a) 25
- (b) 625
- (c) 1
- (d) Nic od nastetega.

Zanima nas verjetnost, da odgovorimo pravilno.

2 Verjetnostni model za nas primer

Vzorec X_1, X_2, \dots, X_n , kjer je: $X_i \sim \text{Bern}(\theta) = \text{Bin}(n=1, \theta)$

- n stevilo studentov na vajah,
- X_i predstavlja pravilnost odgovora i -tega studenta, tj. $X_i = 1$, ce i -ti student odgovori pravilno, in $X_i = 0$, ce le-ta odgovori napacno.

Preucujemo $X_1 + X_2 + \dots + X_n$, tj. stevilo vseh pravilnih odgovorov, ki ga oznamo z X (druga standardna oznaka je Y v smislu izida, anglesko *outcome*).

- $X | \theta \sim \text{Bin}(n, \theta)$
- $P(X = k | \theta) = \binom{n}{k} \theta^k (1 - \theta)^{n-k}$, $k = 0, 1, 2, \dots, n$
- θ (na predavanjih ϑ) je verjetnost pravilnega odgovora – **parameter, ki nas zanima**
- $E(X) = n\theta$ \rightarrow Studentje nedvism'

Nas primer:

`n <- 26`

$\rightarrow P(\text{pravilni odg.}) \text{ enaka za vsega Studenta}$

Nasi podatki (oznamo s k realizacijo X na nasem vzorcu):

`k <- 6`

2.1 Kako bi ocenili nas parameter s "klasicno" frekventisticno statistiko? Katere metode bi lahko uporabili?

→ Metoda največjega verjetja: $\hat{\theta} = \frac{k}{n}$

→ Metoda momentov: dobimo enako

2.2 Bayesova formula

Na ravni dogodkov:

je proporcionalno

$$P(A | B) = \frac{P(B | A) P(A)}{P(B)} \propto P(B | A) P(A).$$

Na ravni gostot z enotno oznako p (lahko bi pisali tudi f):

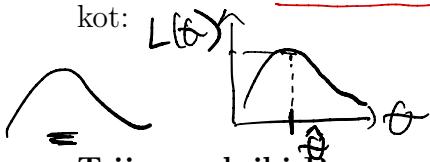
$$p(\theta | \text{podatki}) = \frac{p(\text{podatki} | \theta) p(\theta)}{p(\text{podatki})} \propto p(\text{podatki} | \theta) p(\theta).$$

V "standardnih" oznakah:

$$\Rightarrow \int_{\theta} \pi(\theta | x) d\theta = 1 \rightarrow \pi(\theta | x) = \frac{f(x | \theta) \pi(\theta)}{\int f(x | \theta) \pi(\theta) d\theta} \propto \frac{f(x | \theta) \pi(\theta)}{\int f(x | \theta) \pi(\theta) d\theta}$$

Podatki x so znani. Zanima nas θ . Poglejmo zato na zgornje kot na funkcijo θ .

Spomnimo se funkcije verjetja (anglesko likelihood) $L(\theta | x) = L(\theta; x)$ in zapisimo zgornje kot:



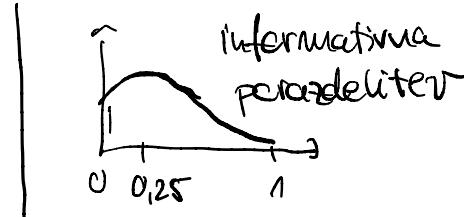
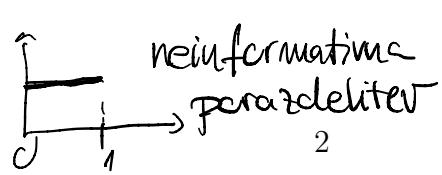
$$\pi(\theta | x) \propto L(\theta | x) \pi(\theta).$$

$$f(x_1, \dots, x_m | \theta) = \prod_{i=1}^m f(x_i | \theta)$$

Trije gradniki Bayesove formule, ki jih bomo predstavili graficno kot funkcije θ :

- Apriorna porazdelitev $\pi(\theta)$ (njen integral je 1) – nase vnaprejsnje (apriorno) vedenje/prepricanje o θ , preden zberemo podatke!
- Verjetje $L(\theta | x)$ (potrebno mnoziti s konstanto, tako da bo integral enak 1) – verjetnost podatkov pri razlicnih moznih vrednostih parametra θ .
- Aposteriorna porazdelitev $\pi(\theta | x)$ – preko Bayesove formule posodobimo nase apriorno vedenje o parametru ($\pi(\theta)$) s tem, kar nam povedo podatki ($L(\theta | x)$).

$$\pi(\theta) \sim \text{Unif}[0,1]$$



$$L(\theta | x) = f(x_1, \dots, x_n | \theta) = \prod_{i=1}^n f(x_i | \theta) = \prod_{i=1}^n \theta^{x_i} (1-\theta)^{1-x_i} = \theta^{\sum_{i=1}^n x_i} (1-\theta)^{\sum_{i=1}^n (1-x_i)} =$$

$\text{Bern}(\theta)$

$$x_i = \begin{cases} 1 & ; \text{prav} \\ 0 & ; \text{nared} \end{cases}$$

$$= \theta^k (1-\theta)^{n-k}$$

2.3 Verjetje

Stevilo pravilnih odgovorov med n studenti je enako k :

$$L(\theta \mid x) = \theta^k (1 - \theta)^{n-k}$$

V R-u:

```
→ verjetje <- function(theta, k, n){  
  dbinom(k, size = n, prob = theta)  
}
```

$$\binom{M}{k} = \binom{26}{6} = \text{large number}$$

#Z mnozenjem s konst dosezemo, da je integral verjetja glede na theta enak 1.

```
konst <- function(k, n){
```

```

theta <- seq(0.001, 1, 0.001)
1 / (0.001 * sum(verjetje(theta, k, n)))
}

```

d — $g(\theta_i)$

Narisemo za nas vzorec:

```
theta <- seq(0, 1, 0.001)
```

```
konst.verjetje <- konst(k, n) * verjetje(theta, k, n)
```

```
plot(theta, konst.verjetje, type = "l",
```

```
    xlab = expression(theta), ylab = "")
```

```
legend("topright", legend = c("verjetje"), col = c("black"),  
      lty = 1, bty = "n", cex = 1.3)      Iskali konst. tezo
```

$\sum \text{Vistura} \cdot \text{Sirusia} =$
 stepai
 $= \sum g(\theta_i) \cdot d =$
 $= d \cdot \sum g(\theta_i)$
 $\doteq \int g(\theta) d\theta$

(*)

Istali konst. teso da bo S cd kanty

$$\text{enaz } \frac{1}{\text{fgetde}} \rightarrow g^{(6)} \text{ iska verietie}$$

$$\cdot g(\omega), \int g(\omega) d\omega \neq 1$$

- Iscemo e farò da $\int c \cdot g(t) dt = 1$.

$$C := \frac{1}{\sigma} \text{sgn}(d), \text{ker}:$$

$$\int c \cdot g(t) dt = c \cdot \int g(t) dt \stackrel{!}{=} \frac{1}{\int g(t) dt} \cdot \int g(t) dt$$

$$c \doteq \frac{1}{d \cdot \sum q(\alpha_i)} = 1 \checkmark$$

po metodi majvečjega verjetja³

$$-6 \overline{)26} = 0,23$$

$$L(\theta|x) = \theta^k (1-\theta)^{n-k}$$

2.4 Apriorna porazdelitev *konjugirana porazdelitev*

Za apriorno porazdelitev si izberemo beta porazdelitev, ki je v primeru binomske porazdelitve podatkov *conjugate prior* (pomeni, da apriorna in aposteriorna porazdelitev pripadata enaki družini porazdelitev), zato se lahko uporablja tudi izraz **beta-binomski model**.

Za apriorno porazdelitev imamo torej gostoto beta porazdelitve pri parametrib $\alpha, \beta > 0$:

$$\pi(\theta) = \pi(\theta | \alpha, \beta) = \frac{1}{B(\alpha, \beta)} \theta^{\alpha-1} (1-\theta)^{\beta-1},$$

kjer je funkcija beta $B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$ in je funkcija gama $\Gamma(a) = (a-1)!$ za pozitivna cela stevila a . Spomnimo se:

- $E(\text{Beta}(\alpha, \beta)) = \frac{\alpha}{\alpha+\beta}$,
- $\text{var}(\text{Beta}(\alpha, \beta)) = \frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$.

$$\theta^{\alpha-1} (1-\theta)^{\beta-1} = \theta^\alpha \cdot (1-\theta)^\beta = 1$$

Najprej poskusimo $\alpha = \beta = 1$, s cimer dobimo enakomerno zvezno porazdelitev $U[0,1]$ - neinformativna apriorna porazdelitev.

Narisemo v R-u:

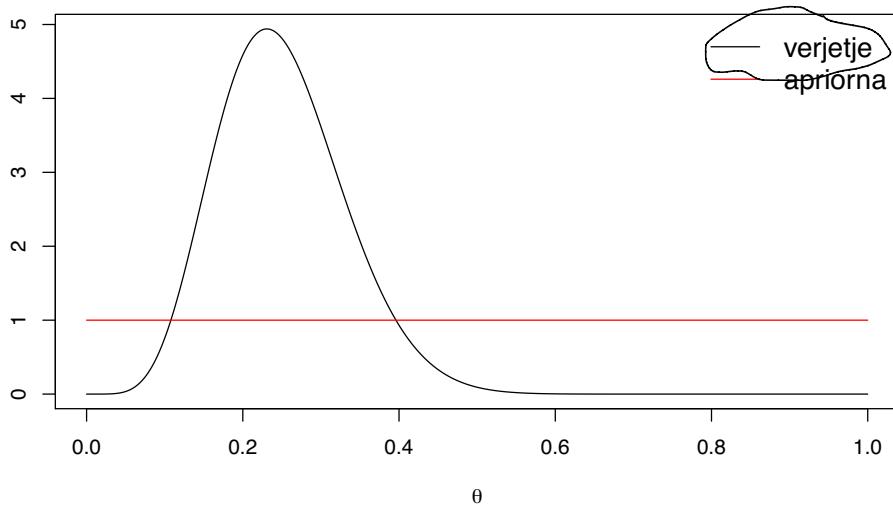
```
alpha <- 1
beta <- 1
```

$$\int_0^1 \theta^0 (1-\theta)^0 d\theta \cdot \theta^6 (1-\theta)^{20}$$

```
theta <- seq(0, 1, 0.001)
apriorna <- dbeta(theta, alpha, beta)
```

```
konst.verjetje <- konst(k, n) * verjetje(theta, k, n) ← posavljeno
```

```
y.max <- max(c(konst.verjetje, apriorna))
plot(theta, konst.verjetje, ylim = c(0, y.max), type = "l",
      xlab = expression(theta), ylab = "")
lines(theta, apriorna, col = "red")
legend("topright", legend = c("verjetje", "apriorna"), col = c("black", "red"),
       lty = 1, bty = "n", cex = 1.3)
```



2.5 Aposteriorna porazdelitev

Ker smo uporabili *conjugate prior*, bo aposteriorna porazdelitev tudi iz družine beta porazdelitev, njena parametra sta enaka:

- $\alpha_{\text{apost}} = k + \alpha$,
- $\beta_{\text{apost}} = n - k + \beta$.

$$L(\theta|x) \cdot \pi(\theta) \propto \theta^k (1-\theta)^{n-k} \cdot \theta^{\alpha-1} (1-\theta)^{\beta-1}$$

$$= \theta^{k+\alpha-1} \cdot (1-\theta)^{n-k+\beta-1}$$
✓

Narisemo v R-u:

```
alpha.apost <- k + alpha
beta.apost <- n - k + beta
```

$\sim \text{Beta}(\alpha_{\text{apost}}, \beta_{\text{apost}})$

```
theta <- seq(0.001, 1, 0.001)
aposteriora <- dbeta(theta, alpha.apost, beta.apost)
```

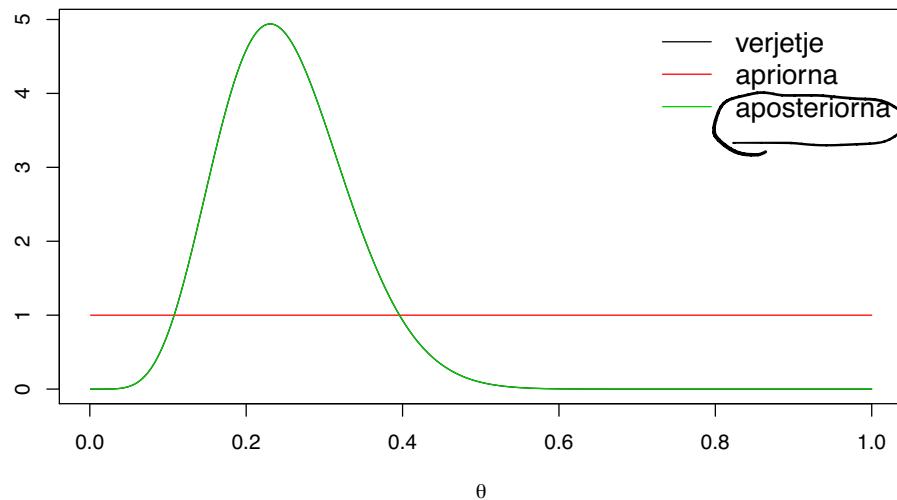
```
konst.verjetje <- konst(k, n) * verjetje(theta, k, n)] ponavili
apriorna <- dbeta(theta, alpha, beta)
```

```
y.max <- max(c(konst.verjetje, apriorna, aposteriora))
plot(theta, konst.verjetje, ylim=c(0, y.max), type = "l",
      xlab = expression(theta), ylab = "")
lines(theta, apriorna, col = "red")
lines(theta, aposteriora, col = "green3")
legend("topright", legend = c("verjetje", "apriorna", "aposteriora"),
       col = c("black", "red", "green3"), lty = 1, bty = "n", cex = 1.3)
```

podatki

frekventistična: $\hat{\theta} \rightarrow$ napaka ocene (SE) \rightarrow interval zaupanja

Bayes: dobimo porazdelitev paramestra, tj. aposteriorna pr.
 $\rightarrow \hat{\theta}$



2.6 Ocena parametra θ

Druga možnost: mediana

Ena možnost je pricakovana vrednost aposteriorne porazdelitve:

$$\hat{\theta} = \frac{\alpha_{\text{apost}}}{\alpha_{\text{apost}} + \beta_{\text{apost}}} = \frac{k + \alpha}{(k + \alpha) + (n - k + \beta)} = \frac{k + \alpha}{n + \alpha + \beta}.$$

alpha.apost / (alpha.apost + beta.apost)

[1] 0.25

Ali dobimo enako kakor pri frekventističnemu pristopu?

k/n

[1] 0.2307692

V primeru neinformativne porazdelitve $\alpha = \beta = 1$, dobimo

$$\hat{\theta} = \frac{k + 1}{n + 2}. \quad \text{uteži (vsota je 1)}$$

Na predavanjih ste $\hat{\theta}$, ocjenjen preko pricakovane vrednosti aposteriorne porazdelitve, zapisali kot

$$\hat{\theta} = \left(\frac{\phi}{\phi + n} \right) \mu + \left(\frac{n}{\phi + n} \right) \cdot \frac{k}{n},$$

kjer je $\mu = E(\text{Beta}(\alpha, \beta)) = \frac{\alpha}{\alpha + \beta}$ in $\phi = \alpha + \beta$.

Ideja: $\hat{\theta}$ je utezeno povprecje med $E(\text{apriorna})$ in $E(X)$, kjer preko ϕ kontroliramo, kako mocno verjamemo apriori pricakovani vrednosti.

2.7 Interval (obmocje) zaupanja v Bayesovi statistiki

Pri danih podatkih $X = x$ ima interval $[L_B(x), U_B(x)]$ 95% Bayesovo pokritje za θ , ce velja

$$6/26 \quad P(L_B(x) < \theta < U_B(x) | X = x) = 0,95.$$

kredibilnostni interval, Credible interval

slož. spreu.

Preden zberemo podatke ima interval $[L(X), U(X)]$ 95% frekventisticno pokritje za θ , ce velja

$$P(L(X) < \theta < U(X) | \theta) = 0,95.$$

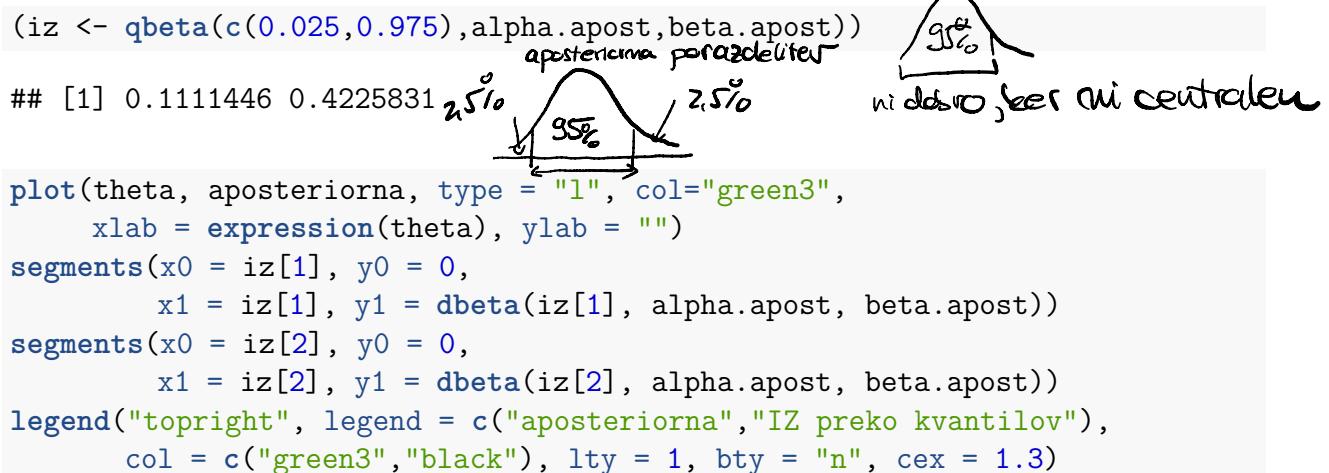
$\theta \rightarrow$ poznate porazdelitev X
 $\rightarrow L(X), U(X)$

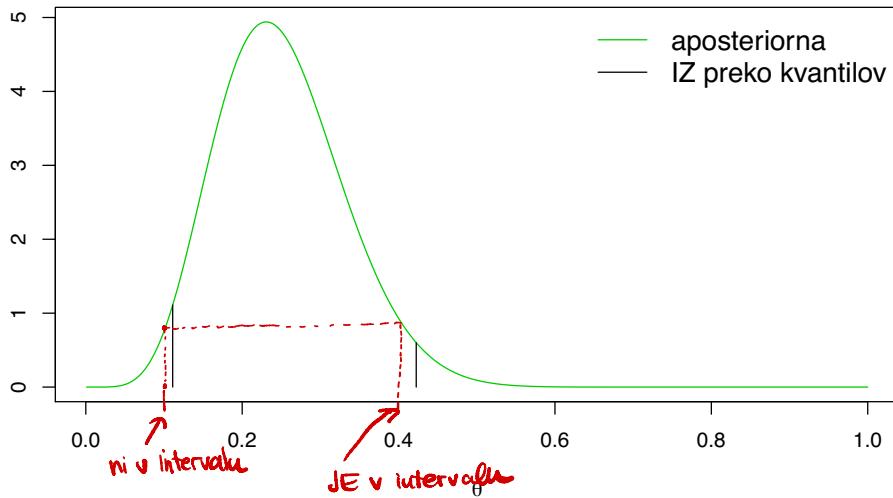
Ko poznamo podatke $X = x$, jih vstavimo v $L(X)$ in $U(X)$ ter s tem dobimo $L(x)$ in $U(x)$.

A
Koliko je $P(L(x) < \theta < U(x) | \theta)$? Ce je $\theta = 0,2$, A = 1
 \uparrow
kvantil
0,1 0,3 0,5, A = 0
Odg.: 0 ali 1. [0,1;0,3] 595% zaupanjem, je θ med 0,1 in 0,3.

Interval zaupanja v Bayesovi statistiki (angl. pogosto *credible interval*, lahko tudi *confidence interval*) je torej katerikoli interval, v katerem "je vsebovanih 95% gostote aposteriorne porazdelitve". Seveda pa zelimo, da je "centralen glede na porazdelitev".

Najbolj preprosta varianta preko kvantilov porazdelitve (smiselna, ce je porazdelitev priblizno simetricna):





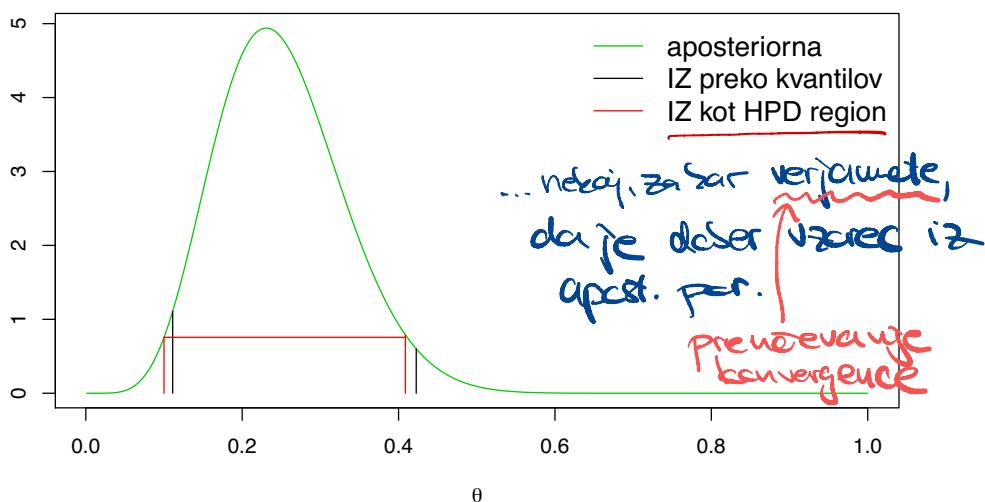
Highest posterior density (HPD) region:

```
#install.packages("HDInterval")
library(HDInterval)

aposteriorna.sample <- rbeta(100000, alpha.apost, beta.apost)
(iz.hdi <- hdi(aposteriorna.sample, credMass = 0.95))

##      lower      upper      NCMC webcode
## 0.1000250 0.4086978
## attr(,"credMass")
## [1] 0.95
```

apost.
zelovite vžerec iz ~~IZ~~ porazdelitve
→ output: vžerec dolocene velikosti iz
apost. porazdelitve ca....



Kaksen interval zaupanja dobimo s frekventisticnim pristopom? Katere intervale zaupanja imamo na voljo?

$$\hat{p} = \frac{k}{n}, \quad \hat{p} \pm 1.96 \cdot \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \quad \text{pravilen } 12 \text{ (največ ... } = 95\% \text{ imenuje}$$

12.1 prop.test(k, n, correct=F)\$conf #IZ z aproksimacijo normalne porazdelitve

```
## [1] 0.1103385 0.4205155
## attr(,"conf.level")
## [1] 0.95
```

$\approx 95\%$

12.2 binom.test(k, n)\$conf #Clopper-Pearsonov IZ

```
## [1] 0.08974011 0.43647510
## attr(,"conf.level")
## [1] 0.95
```

iz #Bayesov IZ, metoda s kvantili

```
## [1] 0.1111446 0.4225831
```

vedno velja: 12.1 < 12.2

2.8 Testiranje hipotez

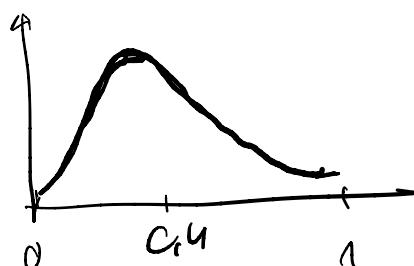
OTS

Namen stirih moznih odgovorov je bil, da je verjetnost pravilnega odgovora brez kakrsnegakoli ucenja dovolj majhna. Ali lahko sklepamo, da je verjetnost pravilnega odgovora manjsa od 0,4? Ali je $\theta < 0,4$?

Kako testiramo to hipotezo s Bayesovim pristopom? Kaj mora biti nicelna in kaj alternativna hipoteza?

Kako testiramo s frekventisticnim pristopom?

apriorno
 π je določen \rightarrow določili π aposteriori



I. način: 95% CI; Ali je CI pod 0,4? Potem: da, lahko
 sklepamo, da $\theta < 0,4$.

II. način: $P(\theta < 0,4) =$ verjetnost vase domnevne.

$P(\theta \leq 0.4)$



#Beayesonski pristop

pbeta(0.4, alpha.apost, beta.apost)

[1] 0.9579073

#Test z aproksimacijo normalne porazdelitve

prop.test(k, n, p = 0.4, alternative = "less", correct = FALSE)\$p.value

[1] 0.03908454

#Binomski eksaktni test → dualen Clopper-Pearsonovega iz
binom.test(k, n, p = 0.4, alternative = "less")\$p.value

[1] 0.05588404 $\Rightarrow H_A$ velja mi $\theta < 0.4$

Frekventistična:

$H_0: \theta \geq 0.4$

$H_A: \theta < 0.4$ ← v alternativno, ker "zelo dobro"

→ test

→ vrednost p

Ce p mojhna, mi verjetno, da H_0 velja pri danih podatkih.

MCMC → Sample = rez.voter

• mean(Sample < 0.4)

• sum(Sample < 0.4) / length(Sample)

• mean(Sample < 0.4)

• sum(Sample < 0.4) / length(Sample)

3 Primerjava dveh neodvisnih delezev

Nase vprasanje iz zacetka navodil tega sklopa zastavimo se skupini studentov, ki se je ucila.

Od 30 studentov, jih je 21 odgovorilo pravilno.

Verjetnost pravilnega odgovora za studenta, ki se uci, naj bo θ_{uci} . Ocenimo jo z uporabo neinformativne apriorne porazdelitve (tako kakor prej, $\alpha = \beta = 1$). Dobimo aposteriorno porazdelitev

$$\theta_{uci} \sim \text{Beta}(21 + 1, 30 - 21 + 1) = \text{Beta}(22, 10).$$

Ocenimo $\hat{\theta}_{uci} = 22/(22 + 10) = 0,6875$.

Kaj smo predpostavili, da smo lahko uporabili ta model?

Prej smo ocenili verjetnost pravilnega odgovora za studenta, ki naključno izbere pravilni odgovor, kot

$$\theta_{blef} \sim \text{Beta}(6 + 1, 26 - 6 + 1) = \text{Beta}(7, 21).$$

Ocenimo $\hat{\theta}_{blef} = 7/(7 + 21) = 0,25$.

Zelimo primerjati ti dve verjetnosti.

Na kaksne nacine ju lahko primerjamo? Katere mere povezanosti lahko izracunamo?

- Razlika delezev (angl. *risk difference*): $\theta_{\text{uci}} - \theta_{\text{blef}}$.
- Relativno tveganje (angl. *risk ratio*): $\theta_{\text{uci}}/\theta_{\text{blef}}$.
- Razmerje obetov (angl. *odds ratio*):

$$\frac{\theta_{\text{uci}}/(1 - \theta_{\text{uci}})}{\theta_{\text{blef}}/(1 - \theta_{\text{blef}})}.$$

Kako ocenimo vsako izmed teh mer?

Ali znate s orodji frekventisticne statistike testirati, da je razlika delezev vecja od nic?

Kako bi testirali, da je relativno tveganje vecje od ena (studentje, ki se ucijo, imajo torej vecjo verjetnost pravilnega odgovora)? Kako bi izracunali interval zaupanja za relativno tveganje?

Frekventisticno?

Bayesovsko?

Moramo pri teh dveh pristopih kaj izpeljati?

```

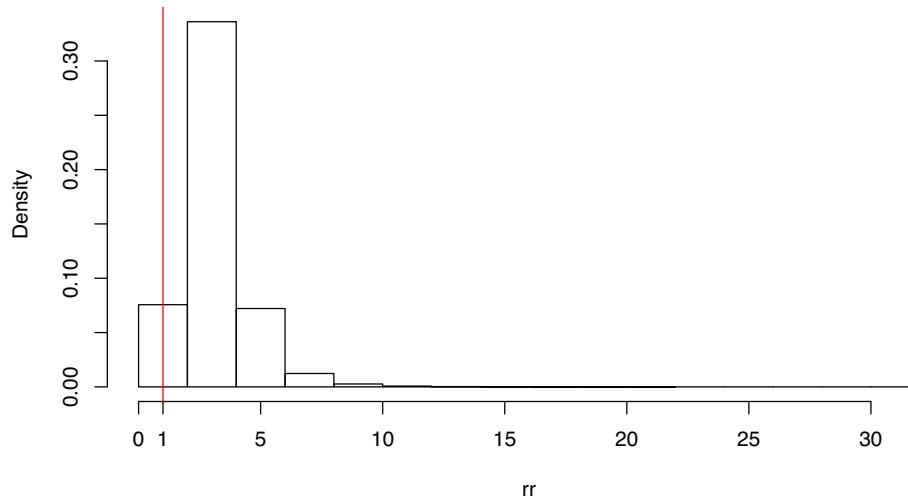
uci <- rbeta(1000000, 22, 10)
blef <- rbeta(1000000, 7, 21)

rr <- uci/blef

hist(rr, prob = TRUE)
axis(1, at = 1)
abline(v = 1, col = "red")

```

Histogram of rr



```

## Ocena:
mean(rr)

## [1] 3.092614

## Interval zaupanja:
quantile(rr, probs = c(0.025, 0.975)) # preko kuantilov

##      2.5%    97.5%
## 1.523910 6.323553

hdi(aposteriorna.sample, credMass = 0.95) #preko HPD region

##      lower      upper
## 0.1000250 0.4086978
## attr(,"credMass")
## [1] 0.95

## Verjetnost hipoteze, da ucenje pomaga:
sum(rr>1)/length(rr)

## [1] 0.999793

```

4 Napovedovanje (angl. *prediction*)

Izpit je sestavljen iz desetih vprasanj (taksnih iz zacetka navodil tega sklopa).

1. Denimo, da bi pred zacetkom prvih vaj dali izpit v resevanje nekemu studentu. Kaj lahko povemo o porazdelitvi stevila njegovih pravilnih odgovorov?
2. Na prvih vajah smo pridobili vzorec, s katerim smo preizkusili, kako na vprasanje odgovarjamo, ce ne znamo cisto nic. Vzorec ste bili studentje, prisotni na prvih vajah. Izpit damo v resevanje studentu, **ki ni bil prisoten na prvih vajah** in se tudi ni učil. Kaj lahko povemo o porazdelitvi stevila njegovih pravilnih odgovorov?

Odgovor na 1. vprasanje je **apriorna napovedna porazdelitev** (angl. *prior predictive distribution*).

Ta nas tipično ne zanima.

Odgovor na 2. vprasanje je **aposteriorna napovedna porazdelitev** (angl. *posterior predictive distribution*).

Splosna formula za apriorno napovedno porazdelitev:

$$f(x_{\text{nov}}) = \int_{\Theta} f(x_{\text{nov}}, \theta) d\theta = \int_{\Theta} f(x_{\text{nov}} | \theta) \pi(\theta) d\theta.$$

Splosna formula za aposteriorno napovedno porazdelitev:

$$f(x_{\text{nov}} | x) = \int_{\Theta} f(x_{\text{nov}}, \theta | x) d\theta = \int_{\Theta} f(x_{\text{nov}} | \theta, x) \pi(\theta | x) d\theta = \int_{\Theta} f(x_{\text{nov}} | \theta) \pi(\theta | x) d\theta.$$

V nasem modelu (binomski model z apriorno beta porazdelitvijo) je:

- $\pi(\theta) \sim \text{Beta}(\alpha, \beta)$; izbrali smo $\alpha = 1, \beta = 1$
- $\pi(\theta | x) \sim \text{Beta}(\alpha_{\text{apost}}, \beta_{\text{apost}}) = \text{Beta}(k + \alpha, n - k + \beta)$; za nas vzorec velikosti $n = 26$ smo dobili $k = 6$
- za $x_{\text{nov}} \equiv K \in \{0, 1, \dots, N\}$ je $f(x_{\text{nov}} | \theta) = \binom{N}{K} \theta^K (1 - \theta)^{N-K}$; dolocili smo $N = 10$, zanimajo nas vsi možni K

Izkaze se, da je iskana apriorna ali aposteriorna napovedna porazdelitev iz družine t.i. **beta-binomske porazdelitve** (BetaBin). To je diskretna porazdelitev Y s parametri $N \in \mathbb{N}$ in $\tilde{\alpha}, \tilde{\beta} > 0$, ki lahko zavzame vrednosti $K \in \{0, 1, \dots, N\}$ in je

$$P(Y = K) = \binom{N}{K} \frac{B(K + \tilde{\alpha}, N - K + \tilde{\beta})}{B(\tilde{\alpha}, \tilde{\beta})}.$$

Apriorna napovedna porazdelitev v binomskem modelu: BetaBin(N, α, β).

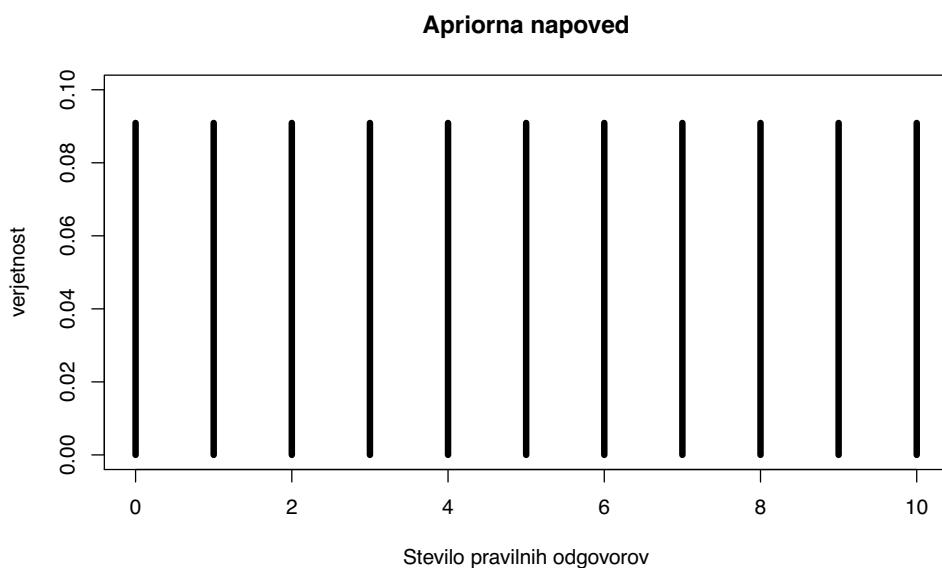
Aposteriorna napovedna porazdelitev v binomskem modelu: BetaBin($N, \alpha_{\text{apost}}, \beta_{\text{apost}}$) ozziroma BetaBin($N, k + \alpha, n - k + \beta$).

Beta-binomska porazdelitev v R (je vkljucena tudi v nekaterih paketih, ponekod drugace parametrizirana):

```
dbetabinom <- function(K, N, a, b){
  choose(N, K) * beta(K+a, N-K+b) / beta(a, b)
}
```

Narisemo apriorno napovedno porazdelitev.

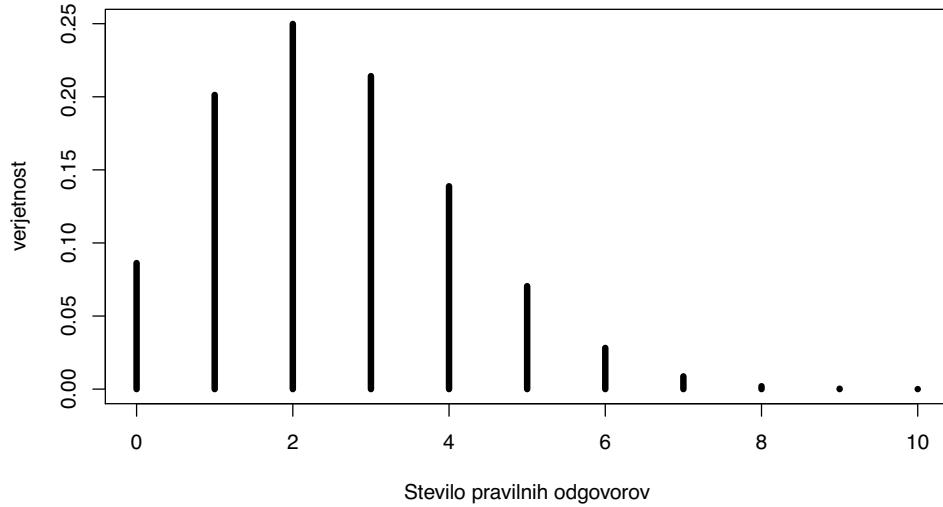
```
plot(0:10, dbetabinom(0:10, N = 10, a = alpha, b = beta), type = "h",
     xlab = "Stevilo pravilnih odgovorov", ylab = "verjetnost",
     main = "Apriorna napoved", ylim = c(0, 0.1), lwd = 5)
```



Narisemo aposteriorno napovedno porazdelitev.

```
plot(0:10, dbetabinom(0:10, N = 10, a = alpha.apost, b = beta.apost), type = "h",
     xlab = "Stevilo pravilnih odgovorov", ylab = "verjetnost",
     main = "Aposteriorna napoved", lwd = 5)
```

Aposteriorna napoved



Ali je bilo vse to racunanje res potrebno?

- Nasa ocena parametra po upostevanju podatkov nasega vzorca je $\hat{\theta} = \alpha_{\text{apost}} / (\alpha_{\text{apost}} + \beta_{\text{apost}}) = 0.25$.
- Stevilo pravilnih odgovorov je porazdeljeno $\text{Bin}(10, \theta)$.
- Ali je preprosto aposteriorna porazdelitev kar $\text{Bin}(10, \hat{\theta})$?

5 Jeffreyeva apriorna porazdelitev

To je **neinformativna** apriorna porazdelitev, ki je proporcionalna $\sqrt{\det \mathcal{I}(\theta)}$. Zanjo je znacilno, da je invariantna glede na razlicne reparametrizacije prostora parametrov.

Pri binomskem modelu je Jeffreyeva apriorna porazdelitev Beta($\alpha = 0.5, \beta = 0.5$).

Pri nasih podatkih dobimo:

