

4. sklop: Algoritem Metropolis-Hastings

Nina Ruzic Gorenjec

Imamo nek model, za katerega poznamo verjetje $L(\theta | x)$ (θ je lahko vektor parametrov, podatki x pa matrika). Odlocimo se za apriorno porazdelitev $\pi(\theta)$, njeni formulo torej poznamo.

Izracunamo torej le se aposteriorno porazdelitev $\pi(\theta | x)$ preko Bayesove formule

$$\pi(\theta | x) \propto L(\theta | x) \pi(\theta).$$

→ To mi se gestela! (*)
→ Hujza normalizacijska konstanta.
→ Interpretacija

Preko aposteriorne porazdelitve izracunamo vse, kar nam srce pozeli: za tockovno oceno vzamemo povprecje ali pa mediano, za interval zaupanja izracunamo primerne kvantile, izracunamo verjetnosti nasih domnev.

Kaj je tu problem?

1 MCMC (Markov Chain Monte Carlo)

Posemo so napisani kljucni korazi (glede angleških izrazov).

Zelimo aposteriorno porazdelitev za parameter θ , natančneje vzorec iz aposteriorne porazdelitve.

Ideja algoritma:

- To je algoritem (sampler) - izberemo med zvez deljenimi mi.
1. Izberemo si zacetno vrednost $\theta^{(0)}$.
 2. Najdemo prizerno porazdelitev $p(\cdot | \cdot)$, tako da bomo lahko na vsakem koraku i dobili $\theta^{(i+1)}$ kot simulacijo iz porazdelitve $p(\theta^{(i+1)} | \theta^{(i)})$.
 3. Po n korakih dobimo realizacijo $\theta^{(0)}, \theta^{(1)}, \dots, \theta^{(n)}$. Postopek ponavljamo dokler ne dosezemo zeljene konvergencije, pri cemer v koncnem vzorcu izpustimo zacetnih nekaj vrednosti (burn-in, npr. m). oz. warm-up
 4. Izbrani vzorec $\theta^{(m+1)}, \theta^{(m+2)}, \dots, \theta^{(n)}$ je vzorec iz aposteriorne porazdelitve.
 5. Preizkusimo razlicne zacetne vrednosti in primerjamo dobljene rezultate.

- (6.) Preizkusimo razlicne apriorne porazdelitve in primerjamo dobljene rezultate.)

mi del preverjanju konvergencije MCMC
Preverjamo, ali je aposteriorna stabilna glede na mnoge spremembe apriorne - sensitivity analysis.

→ Preverjanje konvergencije - kljucno

Če veriga ne "izgleda dobrò" (glejte str. 3) ali verige ob različnih zacetnih vrednostih ne sorodajo,

potem so rezulati za to kritični:

1. Premalo iteracij → postaviti res (10.000, 50.000)

2. Neprimerni algoritmi, tj. prepočasna konvergenca za dani model, ker ne upošteva kakšne lastnosti modela → poskusiti drug algoritem / sampler

3. Model se ne privlači dobro podatki → ugotoviti zalog, spremeni model

2 Algoritem Metropolis-Hastings

Algoritem Metropolis-Hastings je eden izmed MCMC algoritmov.

Najprej si izberemo *proposal distribution* $q(\cdot|\cdot)$, ki je primerne oblike.

En korak Metropolis-Hastings algoritma, ko imamo iz prejšnjega koraka na voljo $\theta^{(i)}$:

1. Simuliramo kandidata θ^* iz porazdelitve $q(\cdot|\theta^{(i)}) \sim N(\theta^{(i)}, \tau_{\text{proposal}}^2)$
 2. Izracunamo verjetnost sprejetja (*acceptance probability*) $\alpha = \min \left\{ 1, \frac{L(\theta^*|x) \pi(\theta^*) q(\theta^{(i)}|\theta^*)}{L(\theta^{(i)}|x) \pi(\theta^{(i)}) q(\theta^*|\theta^{(i)})} \right\}$
 3. Simuliramo u iz enakomerne zvezne porazdelitve na $[0,1]$.
 4. Ce je $u \leq \alpha$, izberemo kandidata (*accept*) in postavimo $\theta^{(i+1)} = \theta^*$.
Ce je $u > \alpha$, zavrnemo kandidata (*reject*) in postavimo $\theta^{(i+1)} = \theta^{(i)}$.
- Če θ^* ustreza podatku, bje "čet" $\theta^{(i)}$
potem je $L(\theta^*|x)$ večje. $\alpha = \min \left\{ 1, \frac{L(\theta^*|x) \pi(\theta^*) q(\theta^{(i)}|\theta^*)}{L(\theta^{(i)}|x) \pi(\theta^{(i)}) q(\theta^*|\theta^{(i)})} \right\}$*
- Torej v DN im spodnjen primeru, to je v splošnem tipično.*
- Ipd za $\pi(\theta^*)$ -ob neinformativni priemi to je v tolkov pomenljivo.*
- Če θ^* "bje" ad $\theta^{(i)}$, bo ta kvocien velik, vecji od 1, zato bo $\alpha = 1$ in zagotovo $u \leq 1 = \alpha$, torej bomo "sprejeli".*
- V nasprotnem primeru, to da $\theta^* < \theta^{(i)}$, rendar bomo "sprejeli", vecino mora spregeti, saj cicer v primeru $u < 1$, torej je vejelo za α . \rightarrow "gambler" korak.*

3 Algoritem Metropolis-Hastings za primer normal-nega modela z znano varianco

Uporabili bomo algoritem Metropolis-Hastings za primer iz 3. sklopa, kjer so bili nasi podatki vzorec visin (metri) studentov moskega spola:

```
x <- c(1.91, 1.94, 1.68, 1.75, 1.81, 1.83, 1.91, 1.95, 1.77, 1.98,
      1.81, 1.75, 1.89, 1.89, 1.83, 1.89, 1.99, 1.65, 1.82, 1.65,
      1.73, 1.73, 1.88, 1.81, 1.84, 1.83, 1.84, 1.72, 1.91, 1.63)
```

Privzeli smo normalni model $N(\theta, \sigma^2 = 0.1^2)$ in zeleli oceniti θ .

Verjetje tega modela je enako

$$L(\theta | x) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi} 0.1} e^{-\frac{(x_i - \theta)^2}{2 \cdot (0.1)^2}}.$$

Za apriorno porazdelitev smo si izbrali normalno porazdelitev (konjugirana v tem modelu) s povprecjem $\mu_0 = 1.78$ in varianco $\sigma_0^2 = 0.2^2$.

Za aposteriorno porazdelitev smo zato dobili normalno porazdelitev s parametrom μ_n in σ_n^2 , kjer je

$$\frac{1}{\sigma_n^2} = \frac{1}{\sigma_0^2} + \frac{n}{\sigma^2},$$

$$\mu_n = \frac{1/\sigma_0^2}{1/\sigma_0^2 + n/\sigma^2} \mu_0 + \frac{n/\sigma^2}{1/\sigma_0^2 + n/\sigma^2} \bar{x}.$$

(Zapisemo lahko tudi preko *precision=1/varianca*.)

Pravo aposteriorno porazdelitev torej poznamo. \rightarrow HMC ne potrebuje
 \rightarrow Naredimo HMC, da lahko evaluiramo konvergenco
 » pravo aposteriorno - tega v praksi ne bomo nagnili naresti.«


Sedaj jo bomo aproksimirali s pomočjo Metropolis-Hastings algoritma.

Najprej si moramo smiselnno izbrati *proposal distribution* $q(\cdot | \theta^{(i)})$. Katero bi si izbrali?

Normalno s povprejem $\theta^{(i)}$ in nekim standardnim odklonom.

Primer zaporedja iz aposteriorne porazdelitve, ki *izgleda dobro*:

Ena veriga, chain → tipično tocke med redki porazdelitvi




„precavamo“ porazdelitev
znotraj nekega omejujega
območja, večinoma svuječe na nekem
ma ogromno „bolj verjetnejši“
območju.

V temenem primeru ne poznamo
aposteriorne in zato ne vedemo,
katero območje to dočno je.

Na sliki smo za boljso predstavo označili 95% referencni interval prave aposterirone porazdelitve (zeleni crtji) in odmik od povpreca aposteriorne porazdelitve za 3 standardne odklone, tj. 99.7% referencni interval (rdeči crtji). **Pozor:** S tem smo uporabili vedenje o pravi aposteriorni porazdelitvi, ki v realni situaciji ni znana (ravno zato jo z MCMC metodami tudi ocenjujemo).

Pomembno: Cilj konvergencije je porazdelitev, ne pa stevilo.




Tu je cijena aposteriorna simetrična, zato
tudi veriga simetrično raztegnjena
gr. in dol.


Pri asimetrični aposteriorni bi izgledala
pridržno točka (bi pri morskiyji raji):



Če bi bila aposteriorna binodalna, potem bi pri različnih zacetnih vrednostih prečekavali le en vrh:



Oziroma bi veriga skotska med vrhoma, če ta ne bi bila tako ekstremno lotena:



Pozor: To velja če niste, da morate biti načel rezultat, tj. aposteriorna
necija binodalnega. Tipično to ne daje in zato so takšne slike primer
slabega pričaganja modela predstavljene - preučiti razlage in spremenljivi model (po tem, ko
se se prepričali, da ste vseči dočni dolgo rezijo in da ni kram, izberi algoritam, tj. glede str. 1).

3.1 Druga domaca naloga *3 tipi varcnic*

Za primer iz 3. sklopa (uporabite zgornje podatke, model z $\sigma^2 = 0.1^2$ in zgornjo apriorno porazdelitev z $\mu_0 = 1.78$ in $\sigma_0^2 = 0.2^2$ – ti parametri so fiksni) aproksimirajte aposteriorno porazdelitev s pomočjo algoritma Metropolis-Hastings, kjer sledite spodnjim korakom.

1. Sami v R-u sprogramirajte algoritem Metropolis-Hastings za primer ocenjevanja enega parametra oz. za nas primer. Kljucno je, da ga sprogramirate sami, pri cemer splosnost kode in efektivnost implementacije nista pomembni. (Za ta preprost primer boste npr. 40000 iteracij dobili v zelo kratkem casu, ne glede na izbor parametrov v spodnjih tockah ali efektivnost implementacije.) *ker je model zelo preprost – ce traja dolgo, se se ne bo zmotil*
z² proposal
spreminjate tezave
DN
2. Preizkusite ga na nasem primeru, kjer si sami izberite neko smiselno zacetno vrednost in varianco proposal distribution. Rezultate predstavite na naslednji nacin:
 - Narisite celotno dobljeno zaporedje $\theta^{(i)}$ (glede na iteracije i).
 - Narisite le prvih 500 ali pa 5000 clenov.
 - Narisite celotno zaporedje, kjer uporabite ustrezni *burn-in*.
 - Za tako izbrano zaporedje graficno predstavite aposteriorno porazdelitev in jo graficno primerjajte s pravo aposteriorno porazdelitvijo.
 - Ocenite parameter in 95% interval zaupanja za parameter iz izbranega zaporedja ter primerjajte z ocenami iz prave aposteriorne porazdelitve.
3. Pozenite vas algoritem pri neki nesmiselni zacetni vrednosti. **Pozor:** ce boste α implementirali po formuli iz str. 2, potem algoritem pri zelo nesmiselnih zacetnih vrednostih ne bo deloval – zato je potrebno implementirati na ravni logaritma (primerno prilagodite korake algoritma). Rezultate predstavite:
 - Opisite, zakaj konkretno so se pojavile tezave, ce ste uporabili zelo nesmiselno zacetno vrednost in osnovno verzijo algoritma (brez logaritmiranja).
 - Narisite celotno dobljeno zaporedje $\theta^{(i)}$ (glede na iteracije i).
 - Narisite le prvih 500 ali pa 5000 clenov.
 - Narisite celotno zaporedje, kjer uporabite ustrezni *burn-in*.
4. Pri neki smiselni zacetni vrednosti pozenite algoritem pri nekaj razlicnih variancah za *proposal distribution*. Pri izboru pretiravajte v obe smeri (spomnite se, kakšni so po velikosti nasi podatki), tako da boste graficno opazili razlike na prvih npr. 500 iteracijah. Rezultate predstavite:
 - Za vsak primer narisite prvih nekaj (nekje med 500 in 5000) clenov in se celotno zaporedje.
 - Komentirajte razlike in zakaj do njih pride. Kaj in zakaj vas moti pri izbranih primerih?
 - **Bonus vprasanje:** Kakšen bi bil v splošnem (ne vezano na nas vzorec) vas predlog glede izbora variance *proposal distribution* oz. kakšen bi bil predlog za izbor koncnega zaporedja?